

Revisão de Probabilidade e Estatística

1 Principais Ramos da Estatística

Estatística Descritiva

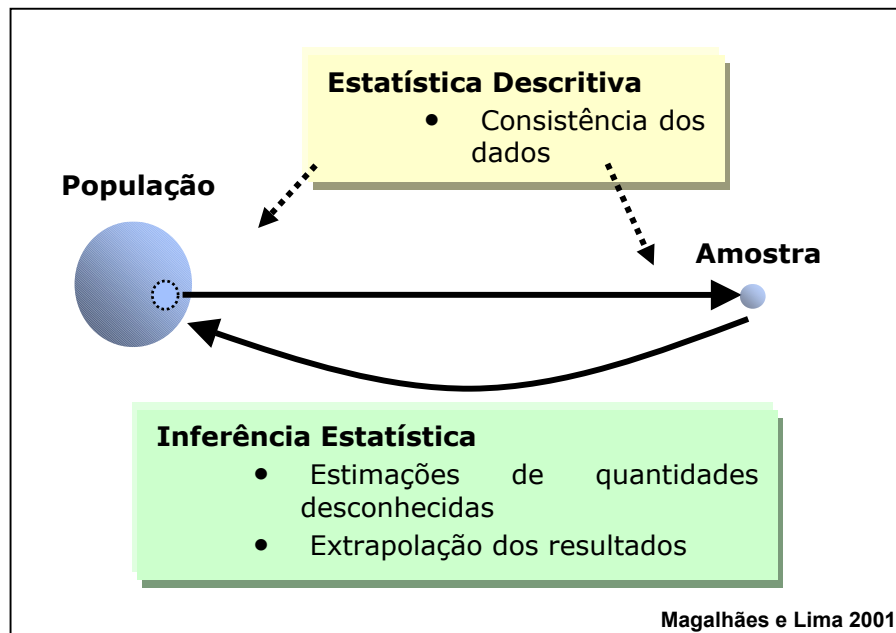
Utilizada na etapa inicial da análise de dados com o objetivo de tirar conclusões iniciais.

Probabilidade

Teoria matemática utilizada para estudar a incerteza decorrente de fenômenos de caráter aleatório.

Inferência Estatística

Estudo de técnicas que permitem a extrapolação, a um grande volume de dados, denominado **população**, de informações e conclusões obtidas de um subconjunto menor de valores, denominado **amostra**.



2 Conceitos de Probabilidades

Experimento

Experimento é um processo cuja saída não é conhecida com certeza. O conjunto de todos os valores possíveis do experimento são chamados de Espaço Amostral.

Espaço Amostral

Espaço Amostral, indicado por S , é o conjunto de todos resultados possíveis de um certo fenômeno aleatório.

Eventos

Eventos ou pontos amostrais, são subconjuntos do espaço amostral.

Variável aleatória

Variável aleatória é uma função que atribui um número real a cada ponto do espaço amostral.

Variável aleatória discreta

Variável aleatória discreta é uma variável aleatória que assume valores enumeráveis x_1, x_2, \dots , isto é, existe uma correspondência 1 a 1 com conjunto dos números inteiros.

Exemplo 1:

No lançamento de uma moeda o espaço amostral é $S = \{\text{cara}, \text{coroa}\}$. A variável aleatória X que indica o valor do resultado pode ser igual a 1 se Cara e 2 se Coroa.

Exemplo 2:

No lançamento de dois dados o espaço amostral é $S = \{(1,1), (1,2), (1,3), \dots, (6,6)\}$. A variável aleatória discreta X , definida como a soma dos dois valores, assume o valor 7 se o resultado for (3,4).

Exemplo 3:

Na chegada de clientes a um banco, o intervalo de tempo entre duas chegadas é uma variável aleatória que assume valores reais positivos.

Probabilidade

Uma função de $P(\cdot)$ é denominada **Probabilidade** se atribui valores numéricos aos eventos do espaço amostral de acordo com as seguintes condições:

(i) $0 \leq P[A] \leq 1$, qualquer $A \subset S$.

(ii) $P[S] = 1$

(iii) $P\left[\bigcup_{j=1}^n A_j\right] = \sum_{j=1}^n P[A_j]$ com os A_j disjuntos

Exemplo 4:

No lançamento de um dado podem ocorrer os valores 1, 2, 3, 4, 5 e 6. O espaço amostral $S = \{1, 2, 3, 4, 5, 6\}$. A probabilidade de ocorrência de cada evento é $p[1]=1/6$, $p[2]=1/6$, $p[3]=1/6$, $p[4]=1/6$, $p[5]=1/6$, $p[6]=1/6$.

2.1 Propriedades de Probabilidades

Sejam A e B eventos de S:

Soma de Probabilidades

$$P[A \cup B] = P[A] + P[B] - P[A \cap B]$$

Produto de Probabilidades

$$P[A \cap B] = P[A | B] P[B] \text{ quando } P[B] > 0$$

Probabilidade Condicional

$$P[A | B] = P[A \cap B] / P[B] \text{ quando } P[B] > 0$$

Independência de Eventos

O evento A não depende do evento B quando $P[A | B] = P[A]$ quando $P[B] > 0$

Partição do Espaço Amostral

C_1, C_2, \dots, C_k é uma partição do Espaço Amostral S se eles não tem intercessão entre si e a união é S.

2.2 Funções de Probabilidade e de Distribuição

A **função de distribuição** $F(x)$ de uma variável aleatória X é definida como:

$$F(x) = P[X \leq x] \text{ para } -\infty < x < \infty$$

A função distribuição $F(x)$ satisfaz às seguintes propriedades:

- (i) $0 \leq F(x) \leq 1$, para todo X
- (ii) $F(x)$ é não decrescente, isto é, se $x_1 < x_2$ então $F(x_1) < F(x_2)$
- (iii) $\lim_{x \rightarrow -\infty} F(x) = 0$ e $\lim_{x \rightarrow \infty} F(x) = 1$

2.3 Funções Discretas de Probabilidade e Distribuição

Função Massa de probabilidade

A **função (massa) de probabilidade** $p[x]$, no caso em que X é uma variável aleatória discreta, é definida como

$$p[x_i] = P[X=x_i] \quad i=1,2,3,\dots$$

que satisfaz a $0 \leq p[x_i] \leq 1$ e $\sum_{i=1}^{\infty} p(x_i) = 1$


Se $I=[a,b]$ então $P(X \in I) = \sum_{a \leq x_i \leq b} p(x_i)$

Função de Distribuição

A **função de distribuição $F(x)$** é dada por $F(x) = \sum_{x_i \leq x} p(x_i)$ para $-\infty < x < \infty$

Exemplo 5:

Em um sistema de estoque, a demanda por um produto é uma variável discreta que assume valores 1, 2, 3, 4 com probabilidades $1/6$, $1/3$, $1/3$ e $1/6$ respectivamente.



2.4 Funções Contínuas de Probabilidade e Distribuição

Função de densidade de probabilidade

Se X é uma variável aleatória contínua então para qualquer conjunto de números reais B existe a **função de densidade de probabilidade $f(x)$** , tal que


$$P[X \in B] = \int_B f(x) dx \quad \text{e} \quad \int_{-\infty}^{\infty} f(x) dx = 1$$

Qualquer x e $\Delta x > 0$ então $P(X \in [x, x + \Delta x]) = \int_x^{x+\Delta x} f(y) dy$

Função de Distribuição

A **função de distribuição $F(x)$** é dada por

$$F(x) = P[X \in [-\infty, x]] = \int_{-\infty}^x f(y) dy \quad \text{para } -\infty < x < \infty$$




Exemplo 6:

Uma variável aleatória uniforme no intervalo $[0,1]$ tem a função densidade de probabilidade:

$$F(x) = \begin{cases} 1 & \text{se } 0 \leq x \leq 1 \\ 0 & \text{Caso contrário} \end{cases}$$

No caso de $0 \leq x \leq 1$ tem-se $F(x) = \int_0^x f(y)dy = \int_0^x 1dy = x$

Os gráficos das funções do exemplo são os seguintes:



2.5 Função de Probabilidade Conjunta

Função de Probabilidade Conjunta – Caso Discreto

Se X e Y são variáveis aleatórias discretas então $p[x,y] = P[X=x, Y=y]$ para todo x,y onde $p[x,y]$ é denominada **função de probabilidade conjunta**.

X e Y são independentes se $p[x,y] = p_X[x] p_Y[y]$ para todo x,y onde

$$p_X[x] = \sum_{\text{todo } y} p[x,y] \quad \text{e} \quad p_Y[y] = \sum_{\text{todo } x} p[x,y]$$

são as probabilidades (marginais) de X e Y .

Exemplo 7:

Supondo que X e Y sejam variáveis aleatórias discretas conjuntas com

$$p[x,y] = \begin{cases} \frac{xy}{27} & \text{para } x=1,2 \text{ e } y=2,3,4 \\ 0 & \text{caso contrário} \end{cases}$$

$$p_x[X] = \sum_{y=2}^4 \frac{xy}{27} = \frac{x}{3} \quad \text{para } x=1,2$$

$$p_y[Y] = \sum_{x=1}^2 \frac{xy}{27} = \frac{y}{9} \quad \text{para } y=2,3,4$$

Considerando que $p[x,y]=xy/27=p_x[x]p_y[y]$ para todo x,y , as variáveis aleatórias X e Y são independentes.

Função Densidade de Probabilidade Conjunta – Caso Contínuo

No caso em que X e Y são variáveis contínuas, se existe a função não negativa $f(x,y)$, chamada **função densidade de probabilidade conjunta** de X e Y , tal que para todos os conjuntos de números reais A e B tem-se

$$P[X \in A, Y \in B] = \int_A \int_B f(x,y) dx dy$$

Neste caso X e Y são independentes se $f(x,y) = f_X(x)f_Y(y)$ para todo x,y onde

$$f_X(x) = \int_{-\infty}^{\infty} f(x,y) dy \quad \text{e} \quad f_Y(y) = \int_{-\infty}^{\infty} f(x,y) dx$$

são as funções densidade de probabilidade de X e Y .

Exemplo 8:

Sendo X e Y variáveis aleatórias contínuas conjuntas com

$$f(x,y) = \begin{cases} 24xy & \text{para } x \geq 0, y \geq 0, \text{ e } x+y \leq 1 \\ 0 & \text{caso contrário} \end{cases}$$

então

$$f_X(x) = \int_0^{1-x} 24xy dy = 12xy^2 \Big|_0^{1-x} = 12x(1-x)^2 \quad 0 \leq x \leq 1$$

e

$$f_Y(y) = \int_0^{1-y} 24xy dx = 12x^2y \Big|_0^{1-y} = 12y(1-y)^2 \quad 0 \leq y \leq 1$$

Como $f(\frac{1}{2}, \frac{1}{2}) = 6 \neq \left(\frac{3}{2}\right)^2 = f_X(\frac{1}{2})f_Y(\frac{1}{2})$ então X e Y não são independentes.

2.6 Média e Desvio Padrão

A **média** ou **valor esperado** de uma variável aleatória X_i (onde $i=1,2,\dots,n$) é indicada como μ_i ou $E[X_i]$ é definida como

$$\mu_i = \begin{cases} \sum_{j=1}^{\infty} x_j p_{x_i}(x_j) & \text{se } X_i \text{ é discreta} \\ \int_{-\infty}^{\infty} x f_{x_i}(x) dx & \text{se } X_i \text{ é contínua} \end{cases}$$

Exemplo 9:

Considerando a variável discreta que assume valores 1, 2, 3, 4 com probabilidades 1/6, 1/3, 1/3 e 1/6 do exemplo 5:

$$\mu = 1\left(\frac{1}{6}\right) + 2\left(\frac{1}{3}\right) + 3\left(\frac{1}{3}\right) + 4\left(\frac{1}{6}\right) = \frac{5}{2}$$

Exemplo 10:

Para a distribuição uniforme entre $[0, 1]$ do exemplo 6:

$$\mu = \int_0^1 x f(x) dx = \int_0^1 x dx = \frac{1}{2}$$

Propriedades da Média

1. $E[cX] = cE[X]$
2. $E\left[\sum_{j=1}^n c_j X_j\right] = \sum_{j=1}^n c_j E[X_j]$ mesmo se X_i forem dependentes

2.7 Variância

A **variância** de uma variável aleatória X_i (onde $i=1,2,\dots,n$) é indicada como σ_i^2 ou $\text{Var}[X_i]$ é definida como

$$\sigma_i^2 = E[(X_i - \mu_i)^2] = E[X_i^2] - \mu_i^2$$

Desvio Padrão é definido como σ_i

Exemplo 11:

Considerando os valores dos exemplos 5 e 9

$$E[X^2] = 1^2\left(\frac{1}{6}\right) + 2^2\left(\frac{1}{3}\right) + 3^2\left(\frac{1}{3}\right) + 4^2\left(\frac{1}{6}\right) = \frac{43}{6}$$

$$\mu = E[X] = 1\left(\frac{1}{6}\right) + 2\left(\frac{1}{3}\right) + 3\left(\frac{1}{3}\right) + 4\left(\frac{1}{6}\right) = \frac{5}{2}$$

$$\text{Var}[X] = E[X^2] - \mu^2 = \frac{43}{6} - \left(\frac{5}{2}\right)^2 = \frac{11}{12}$$

Exemplo 12:

Para a distribuição uniforme entre $[0,1]$ dos exemplos 6 e 10

$$E[X^2] = \int_0^1 x^2 f(x) dx = \int_0^1 x^2 dx = \frac{1}{3}$$

$$\mu = E[X] = \int_0^1 x f(x) dx = \int_0^1 x dx = \frac{1}{2}$$

$$\text{Var}[X] = E[X^2] - \mu^2 = \frac{1}{3} - \left(\frac{1}{2}\right)^2 = \frac{1}{12}$$

Propriedades da Variância

1. $\text{Var}[X] \geq 0$
2. $\text{Var}[cX] = c^2 \text{Var}[X]$
3. $\text{Var}\left[\sum_{j=1}^n X_j\right] = \sum_{j=1}^n \text{Var}[X_j]$ se X_i forem independentes.

2.8 Covariância

A **covariância**, indicada como C_{ij} ou $\text{Cov}(X_i, X_j)$, é uma medida da dependência linear entre as variáveis aleatórias X_i e X_j ($i, j=1, 2, \dots, n$), sendo definida como

$$C_{ij} = E[(X_i - \mu_i)(X_j - \mu_j)] = E[X_i X_j] - \mu_i \mu_j$$

Exemplo 13:

Considerando-se as variáveis aleatórias conjuntas contínuas X e Y do exemplo 8

$$\begin{aligned} E[XY] &= \int_0^1 \int_0^{1-x} xy f(x, y) dy dx = \int_0^1 x^2 \left(\int_0^{1-x} 24y^2 dy \right) dx \\ &= \int_0^1 8x^2 (1-x^3) dx = \frac{2}{15} \end{aligned}$$

$$E[X] = \int_0^1 x f_X(x) dx = \int_0^1 12x^2 (1-x)^2 dx = \frac{2}{5}$$

$$E[Y] = \int_0^1 y f_Y(y) dy = \int_0^1 12y^2(1-y)^2 dy = \frac{2}{5}$$

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = \frac{2}{15} - \left(\frac{2}{5}\right)\left(\frac{2}{5}\right) = \frac{2}{75}$$

Propriedades da Covariância

- Se $C_{ij} = 0$ as variáveis aleatórias X_i e X_j são denominadas **não correlacionadas**.
- Se $C_{ij} < 0$ as variáveis aleatórias X_i e X_j são denominadas **negativamente correlacionadas**.
- Se $C_{ij} > 0$ as variáveis aleatórias X_i e X_j são denominadas **positivamente correlacionadas**.
- Se X_i e X_j são variáveis aleatórias independentes então $C_{ij} = 0$. O inverso não é verdade.

O valor da correlação é um valor com dimensão. Para se obter um valor sem dimensão utiliza-se o índice de correlação ρ_{ij} definido como

$$\rho_{ij} = \frac{C_{ij}}{\sqrt{\sigma_i^2 \sigma_j^2}}$$

2.9 Processos Estocásticos

Um **processo estocástico** é uma coleção de variáveis aleatórias similares ordenadas no tempo, todas definidas em um espaço amostral comum. O conjunto de todos os valores que estas variáveis podem assumir é denominado **espaço de estado**.

Se a coleção é X_1, X_2, \dots , então o processo estocástico é de **tempo-discreto**.

Se a coleção é $\{X(t), t \geq 0\}$, então o processo estocástico é de **tempo-contínuo**.

Exemplo 14:

Uma fila simples tal como a fila M/M/1 com tempos de chegada IID (Independentes e Identicamente Distribuídas) A_1, A_2, \dots , e tempos de serviço IID S_1, S_2, \dots , então podemos definir os atrasos na fila como o processo estocástico de tempo-discreto D_1, D_2, \dots , onde

$$D_1 = 0$$

$$D_{i+1} = \max\{D_i + S_i - A_{i+1}, 0\} \text{ para } i = 1, 2, \dots$$

Desta forma a simulação mapeia as variáveis aleatórias de entrada em um processo estocástico de saída D_1, D_2, \dots . O espaço de estado é o conjunto de números reais não negativos. D_i e D_{i+1} são variáveis aleatórias positivamente correlacionadas.

Exemplo 15:

Na fila do Exemplo 14, seja $Q(t)$ o número de clientes na fila no instante t . Então $\{Q(t), t \geq 0\}$ é um processo estocástico de tempo-contínuo com espaço de estado $0, 1, 2, \dots$

Em alguns casos práticos, para tornar a análise estatística possível, supomos que algumas propriedades do processo estocástico são válidas, tais como a propriedade covariância-estacionária.

Um processo é dito de covariância-estacionária se

$$\begin{aligned} \mu_i &= \mu && \text{para } i=1,2,\dots \text{ e } -\infty < \mu < \infty. \\ \sigma_i^2 &= \sigma^2 && \text{para } i=1,2,\dots \text{ e } \sigma^2 < \infty \\ \text{e } C_{i,i+j} &= \text{Cov}(X_i, X_{i+j}) \text{ são independentes de } i \text{ para } i=1,2,\dots \end{aligned}$$

No caso de covariância-estacionária, a covariância e a correlação entre X_i e X_{i+j} , indicadas como C_j e ρ_j são

$$\begin{aligned} C_j &= C_{i,i+j} \\ \rho_j &= \frac{C_{i,i+j}}{\sqrt{\sigma_i^2 \sigma_{i+j}^2}} = \frac{C_j}{\sigma^2} = \frac{C_j}{C_0} \end{aligned}$$

Se X_1, X_2, \dots , é um processo estocástico começando no tempo 0, é provável que a covariância não seja estacionária. Entretanto, após algum tempo de simulação, isto é, para k suficientemente grande, X_k, X_{k+1}, \dots , serão aproximadamente estacionários. O valor de k para atingir este ponto define o período de “aquecimento” do sistema (“warmup”).

3 Estimadores e Estimativa

Parâmetros

Parâmetros são atributos da população, em geral desconhecidos, e sobre os quais temos interesse de estudo.

Estimador

Estimador é um representante de um parâmetro obtido através de uma amostra.

Estimativa

Estimativa é um valor numérico assumido pelo estimador.

Um **estimador** $\hat{\theta}$ de um parâmetro θ denomina-se **não viciado** se $E[\hat{\theta}] = \theta$

Serão estudados estimadores para dois casos diferentes:

- Variáveis aleatórias Independentes e Identicamente Distribuídas (IID).
- Variáveis aleatórias de um processo estocástico covariante-estacionário.

O segundo caso tem interesse à análise de dados de saída que, em geral, não são independentes.

3.1 Variáveis Aleatórias Identicamente Distribuídas IID

3.2 Estimativa da Média

Supondo que X_1, X_2, \dots, X_n sejam variáveis aleatórias IID com média da população finita μ e variância σ^2 . Então a média

$$\bar{X}(n) = \frac{\sum_{i=1}^n X_i}{n}$$

é um estimador não viciado de μ , isto é, $E[\bar{X}(n)] = \mu$

Intuitivamente, isto significa que se fizermos um número grande de experimentos independentes e calcularmos o $\bar{X}(n)$ para cada experimento, a média dos $\bar{X}(n)$ será μ .

Estimativa da Variância

De forma similar, a variância da amostra $S^2(n)$ é calculada como

$$S^2(n) = \frac{\sum_{i=1}^n [X_i - \bar{X}(n)]^2}{n-1}$$

é um estimador não viciado de σ^2 pois $E[S^2(n)] = \sigma^2$

Os estimadores $\bar{X}(n)$ e $S^2(n)$ são indicados muitas vezes como $\hat{\mu}$ e $\hat{\sigma}^2$.

A dificuldade de se trabalhar com estas estimativas é não se saber o quanto estão próximas do valor μ . Para isto será definido o intervalo de confiança.

Antes disso será feita a estimativa de $\text{Var}[\bar{X}(n)]$

$$\text{Var}[\bar{X}(n)] = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right)$$

Sendo X_i independentes

$$\text{Var}[\bar{X}(n)] = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} n \sigma^2 = \frac{\sigma^2}{n}$$

Da fórmula $\text{Var}[\bar{X}(n)] = \frac{\sigma^2}{n}$ pode-se observar que, quanto maior o valor de n , menor será $\text{Var}[\bar{X}(n)]$ e, em consequência, $\bar{X}(n)$ estará mais próximo de μ .

Além disso, podemos obter um estimador não viciado de $\text{Var}[\bar{X}(n)]$ substituindo σ^2 por $S^2(n)$.

$$\widehat{\text{Var}}[\bar{X}(n)] = \frac{S^2(n)}{n} = \frac{\sum_{i=1}^n [X_i - \bar{X}(n)]^2}{n(n-1)}$$

3.3 Variáveis Aleatórias de um Processo Estocástico Covariante-estacionário

Quando as variáveis aleatórias X_1, X_2, \dots, X_n não forem IID mas definirem um processo estocástico com co-variância estacionária então a média amostral $\bar{X}(n)$ ainda é um estimador não viciado de μ mas a variância $S^2(n)$ não é mais um estimador não viciado de σ^2 pois pode-se mostrar que:

$$E[S^2(n)] = \sigma^2 \left[1 - 2 \frac{\sum_{j=1}^{n-1} (1 - j/n) \rho_j}{n-1} \right]$$

Se $\rho_j > 0$ (correlação positiva), que é um caso comum na prática, então $E[S^2(n)] < \sigma^2$.

A estimativa da variância da média amostral $\text{Var}[\bar{X}(n)]$, quando X_1, X_2, \dots, X_n são variáveis aleatórias de um processo estocástico com co-variância estacionária, é:

$$\text{Var}[\bar{X}(n)] = \sigma^2 \frac{[1 + 2 \sum_{j=1}^{n-1} (1 - j/n) \rho_j]}{n}$$

Assim, estimar $\text{Var}[\bar{X}(n)]$ por $S^2(n)/n$ resulta em duas fontes de erros:

- $S^2(n)$ é um estimador viciado de σ^2 e
- Os termos de correlação foram negligenciados na fórmula acima.

As estimativas de ρ_j (para $j = 1, 2, \dots, n-1$) podem ser calculadas como:

$$\hat{\rho}_j = \frac{\hat{C}_j}{S^2(n)} \quad \text{e} \quad \hat{C}_j = \frac{\sum_{i=1}^{n-j} [X_i - \bar{X}(n)][X_{i+j} - \bar{X}(n)]}{n-j}$$

O problema com estes estimadores é que são viciados e possuem uma variância grande, a menos que n seja muito grande, e são correlacionados entre si, isto é, $\text{Cov}(\hat{\rho}_j, \hat{\rho}_k) \neq 0$.

Estas considerações mostram a dificuldade de se analisar os dados de saída por serem correlacionados.

4 Distribuição Normal


Uma variável aleatória X tem distribuição Normal com média μ e variância σ^2 se a sua função densidade é

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad \text{para } -\infty < x < \infty$$

Utiliza-se a notação $X \sim N(\mu, \sigma^2)$.

Propriedades:

- a) $f(x)$ é simétrica em relação a μ
- b) $f(x) \rightarrow 0$ quando $x \rightarrow \pm\infty$
- c) O máximo de $f(x)$ ocorre em $x = \mu$



O cálculo de probabilidades é feito através da integral da função $f(x)$

$$P(a \leq x \leq b) = \int_a^b \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

Esta integral tem solução aproximada e existe disponível a tabela de $N(0,1)$, isto é, função distribuição Normal com média 0 e variância 1, que é denominada **Normal Padrão** ou **Reduzida**.

Para obter as probabilidades considerando outros valores de média e variância deve ser feita uma transformação como a seguir.

Seja a variável X com distribuição $N(\mu, \sigma^2)$, isto é $E[X] = \mu$ e $\text{Var}[X] = \sigma^2$.

Definimos uma variável $Z = (X - \mu) / \sigma$ que tem média 0 e variância 1 como é mostrado a seguir:

$$E[Z] = E[(X - \mu) / \sigma] = E[X - \mu] / \sigma = (E[X] - \mu) / \sigma = 0$$

$$\text{Var}[Z] = \text{Var}[(X - \mu) / \sigma] = \text{Var}[X - \mu] / \sigma^2 = \text{Var}[X] / \sigma^2 = 1$$

Pode-se verificar que Z tem distribuição Normal(0,1).

Para determinar $P[a \leq X \leq b]$ faz-se

$$P(a \leq X \leq b) = P(a - \mu \leq X - \mu \leq b - \mu) \\ = P\left(\frac{a - \mu}{\sigma} \leq \frac{X - \mu}{\sigma} \leq \frac{b - \mu}{\sigma}\right) = P\left(\frac{a - \mu}{\sigma} \leq Z \leq \frac{b - \mu}{\sigma}\right)$$

Exemplo 16:


Considerando que X tem distribuição $N(2,9)$, para determinar $P[2 \leq X \leq 5]$ faz-se:

$$P(2 \leq X \leq 5) = P\left(\frac{2-2}{\sqrt{9}} \leq Z \leq \frac{5-2}{\sqrt{9}}\right) = P(0 \leq Z \leq 1)$$

Neste caso basta procurar o valor correspondente na tabela que é $P[0 \leq Z \leq 1] = 0,3413$.

Notar que as tabelas $N(0,1)$ fornecem $P[0 \leq Z \leq c]$.

Distribuição Normal Padrão



5 Intervalo de Confiança e Testes de Hipóteses

Sejam X_1, X_2, \dots, X_n variáveis aleatórias IID com média da população finita μ e variância σ^2 ($\sigma^2 > 0$). Veremos como construir um intervalo de confiança de μ e como testar a hipótese de $\mu = \mu_0$.

5.1 Teorema Central do Limite

Seja a variável aleatória Z_n definida como $z_n = \frac{\bar{X}(n) - \mu}{\sqrt{\sigma^2/n}}$ e seja $F_n(z)$ a função de

distribuição de Z_n para uma amostra de tamanho n , isto é, $F_n(z) = P[Z_n \leq z]$.

Então $F_n(z) \rightarrow \Phi(z)$ quando $n \rightarrow \infty$, onde $\Phi(z)$ é a função de distribuição normal de uma variável aleatória Z com média 0 e variância 1, isto é, $N(0,1)$.

$$\Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-\frac{y^2}{2}} dy \quad \text{para } -\infty < z < \infty$$

Na prática o teorema diz que quando n for suficiente grande, a variável aleatória Z_n será distribuída aproximadamente como uma variável com distribuição normal, independente da distribuição das variáveis X_i .

Também pode ser demonstrado que quando n for grande então a média amostral $\bar{X}(n)$ tem distribuição aproximadamente normal com média μ e variância σ^2/n .

A dificuldade de utilizar estes resultados é não se conhecer o valor da variância σ^2 . Neste caso se utilizará $S^2(n)$ que converge para σ^2 quando n se torna grande.

O novo enunciado do teorema, com esta alteração, ficará “Quando n for suficientemente grande, a variável $t_n = \frac{\bar{X}(n) - \mu}{\sqrt{S^2(n)/n}}$ terá distribuição aproximada à de uma variável com distribuição normal $N(0,1)$.”

5.2 Intervalo de Confiança


Será considerada a variável aleatória Z_n , definida no Teorema Central do Limite, com distribuição Normal $N(0,1)$.

Fixado um valor α tal que $0 < \alpha < 1$, podemos encontrar um valor $z_{1-\alpha/2}$ tal que

$$P[|Z_n| < z_{1-\alpha/2}] = P[-z_{1-\alpha/2} < Z_n < z_{1-\alpha/2}] = 1 - \alpha$$

Neste caso, dado α procura-se na tabela de $N(0,1)$ o valor de $z_{1-\alpha/2}$ tal que

$$P[-z_{1-\alpha/2} < Z_n < z_{1-\alpha/2}] = 1 - \alpha.$$



Em lugar de z_n usaremos t_n definido pela fórmula

$$t_n = \frac{\bar{X}(n) - \mu}{\sqrt{S^2(n)/n}}$$

Neste caso tem-se

$$P\left[-z_{1-\alpha/2} \leq \frac{\bar{X}(n) - \mu}{\sqrt{S^2(n)/n}} \leq z_{1-\alpha/2}\right] = 1 - \alpha$$

que pode re-escrita como

$$P\left[\bar{X}(n) - z_{1-\frac{\alpha}{2}} \sqrt{\frac{S^2(n)}{n}} \leq \mu \leq \bar{X}(n) + z_{1-\frac{\alpha}{2}} \sqrt{\frac{S^2(n)}{n}}\right] = 1 - \alpha$$

Assim, para n suficientemente grande, o intervalo com $100(1 - \alpha)$ por cento de confiança para μ , é definido como

$$\bar{X}(n) \pm z_{1-\alpha/2} \sqrt{\frac{S^2(n)}{n}}$$

ou

$$[\bar{X}(n) - z_{1-\frac{\alpha}{2}} \sqrt{\frac{S^2(n)}{n}}, \bar{X}(n) + z_{1-\frac{\alpha}{2}} \sqrt{\frac{S^2(n)}{n}}]$$

Dado o conjunto X_1, X_2, \dots, X_n de variáveis, chamamos

$$l(n, \alpha) = \bar{X}(n) - z_{1-\alpha/2} \sqrt{\frac{S^2(n)}{n}} \quad \text{limite inferior do intervalo de confiança e}$$

$$u(n, \alpha) = \bar{X}(n) + z_{1-\alpha/2} \sqrt{\frac{S^2(n)}{n}} \quad \text{limite superior do intervalo de confiança e}$$

o intervalo de confiança será $[l(n, \alpha), u(n, \alpha)]$.

A interpretação para o intervalo de confiança é:

“Se construirmos um número grande de intervalos de confiança $100(1 - \alpha)$, independentes e baseados em n observações, para n suficientemente grande, a proporção desses intervalos que contem μ é $(1 - \alpha)$. Esta proporção define a cobertura do intervalo de confiança”

O intervalo de confiança dá uma idéia de quão preciso é o valor de μ .

A construção do intervalo de confiança depende da escolha de um n “suficientemente grande”. Quanto mais assimétrica for a distribuição dos X_i 's maior deve ser o valor de n . Se n não for suficientemente grande, o intervalo de confiança será aproximado.


Tem-se uma forma alternativa para determinar o intervalo de confiança. Se as variáveis X_i 's têm distribuição normal, então $t_n = [\bar{X}(n) - \mu] / \sqrt{S^2(n)/n}$ tem distribuição t (t-Student) com $n-1$ graus de liberdade (df).

Neste caso, um intervalo de confiança exato para μ com porcentagem $100(1 - \alpha)$, para $n \geq 2$, é dado por

$$\bar{X}(n) \pm t_{n-1, 1-\alpha/2} \sqrt{\frac{S^2(n)}{n}}$$

O valor de $t_{n-1, 1-\alpha/2}$ é obtido da tabela da distribuição t .

Pode-se observar, pela forma das curvas nos gráficos que $t_{n-1, 1-\alpha/2} > z_{1-\alpha/2}$.



Na prática os X_i 's raramente são normais e o intervalo de confiança dado pela fórmula

$$\bar{X}(n) \pm t_{n-1, 1-\alpha/2} \sqrt{S^2(n)/n}$$

é aproximado.

Pelo fato que $t_{n-1, 1-\alpha/2} > z_{1-\alpha/2}$, o intervalo obtido é mais largo que o obtido com a fórmula

$$\bar{X}(n) \pm z_{1-\alpha/2} \sqrt{S^2(n)/n}$$

e, portanto, está mais próximo de cobrir o nível $(1-\alpha)$ desejado.

Deve ser observado que $t_{n-1, 1-\alpha/2} \rightarrow z_{1-\alpha/2}$ quando $n \rightarrow \infty$.

Exemplo 17:

Supondo que 10 observações 1.20, 1.50, 1.68, 1.89, 0.95, 1.49, 1.58, 1.55, 0.50, e 1,09 foram feitas e apresentaram distribuição normal com média μ desconhecida e queremos construir um intervalo de confiança com 90% ($\alpha=0.10$) para μ . Dos dados calculamos

$$\bar{X}(10) = 1,34$$

$$S^2(10) = 0,17$$

Com estes resultados e consultando a tabela da distribuição t calculamos

$$\bar{X}(10) \pm t_{9, 0.95} \sqrt{S^2(10)/10} = 1.34 \pm 1.83 \sqrt{0.17/10} = 1.34 \pm 0.24$$

Com este resultado podemos dizer com 90 % de confiança que μ está no intervalo [1.10, 1.58].

A cobertura do intervalo de confiança pode ser afetada pelas distribuições dos X_i 's como mostra o experimento a seguir.

Exemplo 18:

Foram realizados 500 experimentos independentes para cada tamanho de amostra $n=5$, 10, 20 e 40, com distribuições normal, exponencial, chi-quadrado com 1df (normal ao

quadrado), lognormal (e^Y onde Y é normal) e hiperexponencial ($F(x)=0.9F_1(x)+0.1F_2(x)$ sendo F_1 e F_2 exponenciais com médias 0.5 e 0.55).

As estimativas de cobertura dos intervalos de confiança de 90% são mostrados na tabela a seguir.

Distribuição	Assimetria u	N=5	N=10	N=20	N=40
Normal	0.0	0.910	0.902	0.898	0.900
Exponencial	2.0	0.854	0.878	0.870	0.890
Chi-quadrado	2.83	0.810	0.830	0.848	0.890
Lognormal	6.18	0.758	0.768	0.842	0.852
Hiperexponencial	6.43	0.584	0.586	0.682	0.774

A assimetria u é definida como:

$$u = \frac{E[(X - \mu)^3]}{(\sigma^2)^{3/2}} \quad \text{para } -\infty < u < \infty$$

Pela tabela pode-se observar que a cobertura atinge valores próximos de 90% quando n se torna maior. Além disso, esta aproximação demora mais a ocorrer nos casos de distribuições mais assimétricas.

5.3 Teste de Hipóteses

Dado o conjunto X_1, X_2, \dots, X_n de variáveis aleatórias normalmente distribuídas, queremos testar a hipótese nula H_0 , de que $\mu = \mu_0$, onde μ_0 é um hipotético valor de μ .

Intuitivamente espera-se que, se $|\bar{X}(n) - \mu_0|$ for um valor grande então é provável que H_0 seja falsa.

Entretanto, para desenvolver um teste com propriedades estatísticas precisamos de uma estatística dos X_i 's cuja distribuição seja conhecida e onde H_0 seja verdade.

Do que foi discutido, se H_0 é verdadeira a estatística

$$t_n = [\bar{X}(n) - \mu_0] / \sqrt{S^2(n)/n}$$

terá distribuição t com $n-1$ graus de liberdade.

Desta forma, indo de encontro à intuição, o teste de hipótese para $\mu = \mu_0$ é

$$\text{Se } |t_n| \begin{cases} > t_{n-1, 1-\alpha/2} & \text{rejeitar } H_0 \\ \leq t_{n-1, 1-\alpha/2} & \text{aceitar } H_0 \end{cases}$$

O conjunto de todos os x tais que $|t_n| > t_{n-1, 1-\alpha/2}$, isto é, correspondem a rejeitar H_0 , é chamado **região crítica** para o teste.

A probabilidade α que a estatística t_n caia na região crítica, considerando que H_0 é verdadeira, é chamada **nível do teste**.

Quando realizamos um teste podem ocorrer dois tipos de erros :

- a) **Erro tipo I:** Se rejeitamos a hipótese H_0 quando H_0 é verdadeira. A probabilidade deste tipo de erro é α e está sob controle.
- b) **Erro tipo II:** Se aceitamos a hipótese H_0 quando H_0 é falsa. Para um nível α e uma amostra de tamanho n , a probabilidade deste erro, que indicaremos por β , depende do μ que é verdadeiro e pode ser desconhecido.

Chamamos $\delta = 1 - \beta$ o **poder do teste** sendo a probabilidade de rejeitar H_0 quando H_0 é falso.

Exemplo 19:

Para os dados do exemplo 18, suponhamos que queremos testar a hipótese nula H_0 tal que $\mu = 1$ no nível $\alpha = 0.10$.

$$\text{Como } t_{10} = \frac{\bar{X}(10) - 1}{\sqrt{S^2(10)/10}} = \frac{0.34}{\sqrt{0.17/10}} t_{10} = 2.65 > 1.83 = t_{9,0.95}$$

então H_0 será rejeitada.

Existe uma relação próxima entre o intervalo de confiança definido por

$$\bar{X}(n) \pm t_{n-1, 1-\alpha/2} \sqrt{S^2(n)/n}$$

e o teste de hipóteses definido por

$$|t_n| \begin{cases} > t_{n-1, 1-\alpha/2} & \text{rejeitar } H_0 \\ \leq t_{n-1, 1-\alpha/2} & \text{aceitar } H_0 \end{cases}$$

A rejeição da hipótese nula H_0 de que $\mu = \mu_0$, é equivalente a μ_0 não estar contido no intervalo de confiança para μ , assumindo o mesmo valor de α tanto para o teste de hipóteses quanto para o intervalo de confiança.

Lei dos Grandes Números: Teorema

Sejam X_1, X_2, \dots, X_n variáveis aleatórias IID com média finita μ . Então $\bar{X}(n) \rightarrow \mu$ com probabilidade 1, quando $n \rightarrow \infty$.

6 Bibliografia

- [1] Magalhães, M. N., Lima, A. C. P., "Noções de Probabilidade e Estatística", 3 ed., IME-USP, São Paulo, 2001, 375p.
- [2] Law, A. M., Kelton, W. D., "Simulation Modeling and Analysis", 3rd ed., McGraw-Hill Companies Inc, 2000, ISBN 0-07-059292-6, 760p.
- [3] Cassandras, C. G., "Discrete Event Systems: Modeling and Performance Analysis", Aksen Associates Incorporated Publishers, 1993, ISBN: 0-256-11212-6, 790p.