

# Redes Bayesianas 1

Matheus Cafalchio  
Paulo Moreira

## Teoria da Probabilidade

- Associa às sentenças um grau de crença numérico entre 0 e 1
  - Contudo, cada sentença ou é **verdadeira** ou é **falsa**. (O grau de crença é associado ao meu conhecimento sobre a sentença, e não sobre a sentença em si).
- Grau de crença(probabilidade):
  - a priori(incondicional): calculado antes do agente receber percepções
    - Ex.  $P(\text{cárie}) = 0.5$
  - condicional: calculado de acordo com as **evidências** disponíveis
    - **evidências**: percepções que o agente recebeu até agora
    - Ex:  $P(\text{cárie}|\text{dor de dente}) = 0.8$   
 $P(\text{cárie}|\neg \text{dor de dente}) = 0.3$

## Probabilidade condicional

- Probabilidade condicional (a posteriori) de A dado que B ocorreu é definida por:
  - $P(A|B) = \frac{P(A \wedge B)}{P(B)}$ , quando  $P(B) > 0$ . **Regra do Produto**
  - ou  $P(A \wedge B) = P(A|B) * P(B)$
- Possibilita inferência sobre uma proposição desconhecida A dada a evidência B

## Independência

- Independência **absoluta**:
  - $P(A|B) = P(A)$
  - Exemplo: A = dor de dente e B=úlceras
    - Úlcera não causa dor de dente
- Independência **condicional**:
  - Seja X e Y condicionalmente independentes dado Z =>  $P(X|Y,Z) = P(X|Z)$  ou  $P(X,Y|Z) = P(X|Z)P(Y|Z)$
  - Independência condicional é crucial para o funcionamento eficaz de sistemas probabilísticos.

## Regra de Bayes

- **Thomas Bayes** (1702 - 1761) : matemático inglês e pastor presbiteriano.
- Seu teorema pode ser derivado a partir da regra do produto:
$$\frac{P(a \wedge b)}{P(a \wedge \neg b)} = \frac{P(a|b)P(b)}{P(a|\neg b)P(\neg b)}$$
$$\frac{P(a \wedge b)}{P(a \wedge \neg b)} = \frac{P(b|a)P(a)}{P(b|\neg a)P(\neg a)}$$

Igualando os membros da direita e dividindo por  $P(b)$  :

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$
- Base de todos os sistemas modernos de IA para inferência probabilística, permite lidar com eventos condicionalmente independentes.

## Estrutura de uma rede

- Um conjunto de variáveis aleatórias definem os nós da rede
- Um conjunto de setas ligam as variáveis, se uma seta liga X em direção a Y, então X é "pai" de Y
- Cada nó Y tem uma distribuição de probabilidade condicional  $P(Y_i | \text{pais}(Y_i))$
- O grafo não tem ciclos orientados
- Cada nó possui uma tabela de probabilidade condicional que quantifica a influência dos pais sobre os filhos

## Estrutura de uma rede




TABELA DE PROBABILIDADE CONDICIONAL

## Estrutura de uma rede

Tabela de probabilidade condicional (TPC)

Cada linha é um caso de condicionamento

Um caso de condicionamento é uma combinação possível de valores dos pais

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i | \text{pais}(X_i))$$

## Contruindo uma rede

- Utilizando a regra do produto:

$$P(X_1, \dots, X_n) = P(X_n | X_{n-1}, \dots, X_1) P(X_{n-1}, \dots, X_1)$$

- Repetimos o processo, reduzimos cada probabilidade conjuntiva a uma condicional mais uma conjunção menor

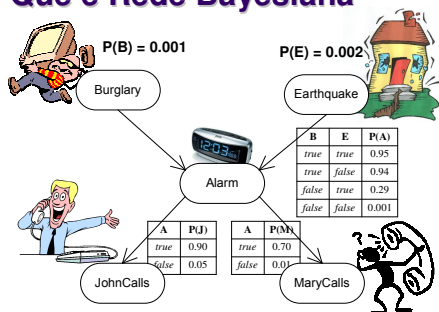
No final teremos:

$$\prod_{i=1}^n P(X_i | X_{i-1}, \dots, X_1) \quad \text{REGRA DA CADEIA}$$

## Contruindo uma rede

- Escolher as variáveis pertinentes ao problema
- Ordem de inserção:
  - 1 Inserir os nós "raízes"
  - 2 Variáveis que eles influenciam
  - 3 Nós folhas (não influenciam nenhuma variável)
- Enquanto houver variáveis para representar:
  - 1 Adicionar um nó para ela,  $X_n$
  - 2 Estabelecer pais( $X_n$ ) dentre os nós já existentes
  - 3 Definir a tabela de probabilidade condicional

## O Que é Rede Bayesiana



A Rede mostra valores de  $P(X_i | \text{Parents}(X_i))$

## Inferência Bayesianas

Segundo [CASTILHO & GUTIERREZ, 1997] há três tipos distintos de algoritmos de inferência:

- **Exatos**
  - Enumeração
  - Eliminação de Variáveis
  - Junction Tree

Obs: Inferência exata é intratável para redes grandes e muito conectadas
- **Aproximados**
  - Forward Sampling [RUSSEL & NORVIG, 2004]
  - Likelihood Weighting [FUNG & CHANG, 1990; RUSSEL & NORVIG, 2004]
  - Gibbs Sampling [GEMAN & GEMAN, 1984; RUSSEL & NORVIG, 2003]
  - Metropolis-hasting
- **Simbólicos**




$$P(b \mid j, m) = \alpha (P(b) \cdot (P(e) \cdot (P(a \mid b, e) \cdot P(j \mid a) \cdot P(m \mid a) + P(\sim a \mid b, e) \cdot P(j \mid \sim a) \cdot P(m \mid \sim a)) + P(\sim e) \cdot (P(a \mid b, \sim e) \cdot P(j \mid a) \cdot P(m \mid a) + P(\sim a \mid b, \sim e) \cdot P(j \mid \sim a) \cdot P(m \mid \sim a))))$$

$$P(b \mid j, m) = \alpha \cdot 0,00059224$$

Grupo 7: André Zan Ramos  
João Paulo Fiori  
Roberto Thiele

Alexandre Shiroma – 5174737  
Celso de Almeida Saad – 5123393  
Márcio Yudi Sato - 5179979

## Processos Estacionários e a suposição de Markov



- O modelo de transição:  $P(Rain_t | Rain_{t-1})$ .
- O modelo sensor:  $P(Umbrella_t | Rain_t)$ .

## Inferência em modelos temporais



- **Filtragem:** computar o estado de crença atual, dada toda a evidência até ao momento, ou seja, computar  $P(X_t | e_{1:t})$ .
- **Previsão:** computar distribuição posterior sobre algum estado futuro, dada toda a evidência até ao momento, ou seja, computar  $P(X_{t+k} | e_{1:t})$  para  $k > 0$
- **Suavização:** computar a distribuição posterior sobre algum estado passado, dada toda a evidência até ao momento, ou seja, computar  $P(X_k | e_{1:t})$  para  $0 \leq k < t$ .

## Lidando com a Incerteza

### Robótica Probabilística

[Thrun, Burgard, Fox 2005]

- Representação do sistema estocástico dinâmico como uma DBN (Dynamic Bayes Network):  $p(x_t | x_{t-1}, u_t)$



$$p(z_t | x_t)$$


Crença  $bel(x_t)$ : reflete o conhecimento interno do agente a respeito do estado.

21

## Principal algoritmo para calcular crença: Filtro de Bayes

1. Algoritmo filtro\_Bayes ( $bel(x_{t-1}), u_t, z_t$ )
2. para todo  $x_t$  faça
  1.  $bel'(x_t) = \int p(x_t | x_{t-1}, u_t) bel(x_{t-1}) dx_{t-1}$
  2.  $bel(x_t) = \eta \cdot p(z_t | x_t) \cdot bel'(x_t)$
3. fim do para
4. retorne  $bel(x_t)$


Passo 2.1: **predição**  
Passo 2.2: **atualização**




22

## Bayesian Filtering

- Two phases:
  - 1. Prediction Phase
  - 2. Measurement Phase




## 1. Prediction Phase



$$P(x_t) = \sum P(x_t | x_{t-1}, u) P(x_{t-1})$$

Motion Model

## 2. Measurement Phase




$$P(x_t|z) = k P(z|x_t) P(x_t)$$


Sensor Model

## Kalman Filter


- Very powerful
- Gaussian, unimodal




## Sampling as Representation




## 1. Prediction Phase



## 2. Measurement Phase




## 3. Resampling Step




## Global Localization



## Global Localization (2)



## Global Localization (3)



## PROBLEMAS DE DECISÃO SEQUENCIAL

PCS2428/2059 – Inteligência Artificial

Professora :

Anna Helena Realí Costa

Integrantes:

Andre Felipe Santos

Hernan da Cunha Martinez

Leandro Moreira da Costa

nºUSP: 3729471

nºUSP: 5178342

nºUSP: 5178575

06/11/2008

## MDP = (S,A,R,T)

### Processo de Decisão de Markov (MDP):

- S: conjunto finito de estados ( $s \in S$ )
- A: conjunto finito de ações ( $a \in A$ )
- R: função reforço (eventualmente não-determinística)  
 $R: S \times A \rightarrow \mathbb{R}$ ;  
 –  $r(s,a)$  – recompensa obtida por executar  $a$  em  $s$ .
- T: função de transição entre estados (eventualmente não-determinística)  $T: S \times A \rightarrow S$ ;  
 –  $t(s,a,s')$  – (probabilidade de) estando em  $s$  e executando  $a$ , ir para o estado  $s'$ .

**Condição de Markov:** Estado atual depende apenas do último par (estado, ação).

## Política

- Solução para um MDP: determinar uma política.
- **Qual política?** Escolher aquela que produz a **maior recompensa acumulada** possível!
- Para explicar como determinar a política, usaremos o conceito de **função valor**.  
 – Função valor: Indica o valor (numérico) de cada estado.

## Função Valor: exemplo

- Ambiente discreto 4x4, com obstáculos.
- Agente deve alcançar posição destino D a partir de qualquer lugar do ambiente.
- Ações que o agente pode realizar: N, S, L, O.
- Penalidade por executar uma ação (qualquer) = -1
- Melhor política => caminho mais curto.

## Função valor: exemplo


Ambiente exemplo

-7	-6	-5	-6
-6	-5	-4	-5
		-3	-4
D	0	-1	-2

Função valor ótima:  
indica as penalidades esperadas até atingir o destino, seguindo uma política ótima.

↖	↖	↓	↖
→	→	↓	↖
		↓	↖
D	←	←	←

Política ótima obtida a partir da função valor ótima (melhores ações, para cada estado).

## PD: algoritmo de iteração de valor

- Cálculo iterativo da função valor ótima.

$$V(s) \leftarrow \max_a (r_{s,a} + V(s'))$$

Repetir até V(s) estabilizar.

Sendo:

s – estado atual, s' – próximo estado,

$r_{s,a}$  – reforço recebido por executar a em s

$V(\cdot)$  – valor

Modelo determinístico e horizonte finito.

OBS: uso da função de transição entre estados T.

## Exemplo de cálculo de V(s)

0	0	$s_2$	0
0	$s_1$	0	0
		$s_3$	0
D	0	0	0

-1	-1	-1	-1
-1	-1	-1	-1
		-1	-1
D	$s_1$	$s_3$	-1

-2	-2	-2	-2
-2	-2	-2	-2
		-2	-2
D	0	-1	-2

$$V(s) = \max_a ((r(s, O) + V(s')), (r(s, N) + V(s'_2)), (r(s, L) + V(s'_3)), (r(s, S) + V(s'_4)))$$

$$= \max_a ((-1+0), (-1+0), (-1+0), (-1+0))$$

$$= -1$$

$$V(s) = \max_a ((r(s, O) + V(s')), (r(s, L) + V(s'_2)))$$

$$= \max_a ((-1+0), (-1+(-1)))$$

$$V(s) = -1$$

## Política ótima

- $V^\pi(s_t)$ : valor acumulado (descontado) conseguido por seguir a política arbitrária  $\pi$  a partir de um estado arbitrário  $s_t$  ( $a_t = \pi(s_t)$ ,  $a_{t+1} = \pi(s_{t+1}), \dots$ ):

$$V^\pi(s_t) \equiv r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \gamma^3 r_{t+3} + \dots \equiv \sum_{i=0}^{\infty} \gamma^i r_{t+i}$$

(discounted cumulative reward)

- **Política ótima:**  $\pi^* \equiv \operatorname{argmax}_\pi V^\pi(s) \ (\forall s)$

–  $V^*(s)$ : função valor da política ótima  $\pi^*$ .

## Política ótima

- A ação ótima  $a$  no estado  $s$  é aquela que maximiza a soma da recompensa imediata somada ao valor  $V^*$  do estado sucessor imediato, descontado de  $\gamma$ :

$$\pi^*(s) \equiv \operatorname{argmax}_a [r(s,a) + \gamma V^*(s')]$$

Com:  $\pi^*(s)$  – ação ótima no estado  $s$ ;

$V^*(s')$  – máxima recompensa acumulada descontada obtida ao iniciar a partir do estado  $s'$  (seguindo política ótima).