



ESCOLA POLITÉCNICA DA UNIVERSIDADE DE SÃO PAULO

Avenida Professor Luciano Gualberto, travessa 3 nº 158 CEP 05508-900 São Paulo SP

Telefone: (011) 818-5583 Fax (011) 818-5294

Departamento de Engenharia de Computação e Sistemas Digitais

PCS 2428 E PCS 2059

INTELIGÊNCIA ARTIFICIAL

RACIOCÍNIO PROBABILÍSTICO AO LONGO DO TEMPO

ALUNOS:

GRUPO 8

ALEXANDRE SHIROMA	5174737
CELSON DE ALMEIDA SAAD	5123393
MÁRCIO YUDI SATO	5179979

CONTEÚDO

1	Introdução	3
2	Tempo e incerteza	4
2.1	Estados e observações.....	4
2.1.1	Exemplo	4
3	Processos estacionários e a suposição de Markov.....	5
4	Inferência em Modelos Temporais.....	7
4.1	Filtragem ou Monitoramento	7
4.1.1	Exemplo	8
4.2	Previsão.....	8
4.2.1	Exemplo	9
4.3	Suavização.....	9
4.3.1	Exemplo	10
4.4	Explicação mais Provável	10
5	Modelo de Markov Oculto	12

1 INTRODUÇÃO

Agentes em ambientes incertos devem ter a capacidade de manter o estado atual do ambiente, tal como agentes lógicos. Esta tarefa é dificultada pela incerteza sobre como o ambiente muda ao longo do tempo. No melhor dos casos, o agente poderá obter um valor probabilístico acerca da situação atual. O mundo muda, é necessário controlar e prever essas mudanças.

2 TEMPO E INCERTEZA

Exemplos: Tratar um paciente diabético (onde o nível de sangue no sangue, e a quantidade de insulina com que é feito tratamento, muda a cada instante de tempo), monitoramento do trânsito (onde o volume de veículos muda com o passar do tempo).

Processo de mudança visto como uma série de fotografias (ou *time slices*), onde cada uma delas descreve o estado do mundo em um determinado instante de tempo.

2.1 ESTADOS E OBSERVAÇÕES

Cada *time slice* possui um conjunto de variáveis aleatórias:

- X_t – conjunto de variáveis de estado (não-observadas) no instante t .
- E_t – conjunto de variáveis de evidência (observadas) no instante t .

2.1.1 EXEMPLO

Um guarda da segurança está no interior de um edifício e quer saber se está chovendo, mas o seu único acesso ao mundo exterior acontece cada manhã, quando ele vê o diretor entrar com ou sem guarda-chuva.

Por cada dia t :

- E_t contém a variável de evidência U_t (se o guarda-chuva aparece)
- X_t contém a variável de estado R_t (se está chovendo)

A notação $X_{a:b}$ denota o conjunto de variáveis de X_a a X_b

3 PROCESSOS ESTACIONÁRIOS E A SUPOSIÇÃO DE MARKOV

Podemos colocar as variáveis pela ordem temporal natural e fazer questões sobre a independência condicional dos predecessores, dado algum conjunto de pais.

O conjunto de variáveis é ilimitado porque inclui as variáveis de estado e de evidência para cada *time-slice*. Isso cria dois tipos de problemas:

- Podemos ter que especificar um número ilimitado de tabelas de probabilidades condicionadas para cada variável em cada *time-slice*.
- Cada *slice* pode envolver um número ilimitado de pais.

Os processos são *estacionários*. Não confundir com *estáticos*. Um processo estático é aquele que é fixo, que não muda com o passar do tempo, se não houver nenhuma ação. Já um processo estacionário é aquele que muda com o passar do tempo, mas que segue uma regra fixa. Neste caso é possível prever o seu comportamento. Com isso é possível contornar o primeiro problema.

Para o segundo problema, levaremos em conta a Suposição de Markov. A **Suposição de Markov** nos diz que o estado atual depende apenas de um número finito (n) de estados anteriores. Ou seja, X_t depende de um n^o limitado de subconjuntos de $X_{0:t-1}$

Os processos que satisfazem esta suposição são definidos como processos de Markov. Existem várias ordens do tipo n , onde o n representa o número de estados da qual irá depender o estado atual.

Um **Modelo de transição** é a lei que descreve como o estado muda ao longo do tempo:


$$P(X_t | X_{0:t-1}) = P(X_t | X_\alpha) \text{ onde } \alpha \subseteq \{1 \dots t-1\}$$

- Processo de Markov de 1ª ordem:

$$P(X_t | X_{0:t-1}) = P(X_t | X_{t-1})$$

- Processo de Markov de 2ª ordem:

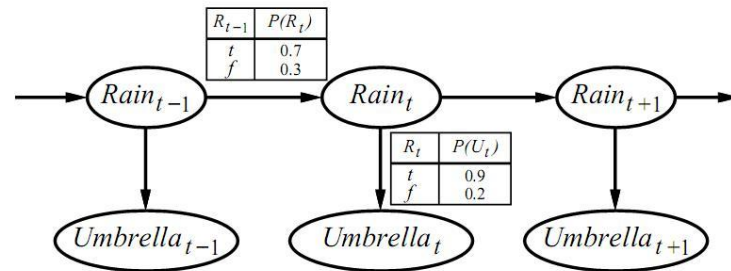
$$P(X_t | X_{0:t-1}) = P(X_t | X_{t-2}, X_{t-1})$$



É assumido que as variáveis de evidência no instante t dependem apenas do estado atual.

O **Modelo Sensor** é a lei que descreve como as variáveis de evidência (sensores) vão ser afetadas pelo estado atual do mundo:

$$P(E_t | X_{0:t}, E_{0:t-1}) = P(E_t | X_t)$$



- O modelo de transição: $P(Rain_t | Rain_{t-1})$.
- O modelo sensor: $P(Umbrella_t | Rain_t)$.
- Processo de Markov de ordem um.

Aproximação de ordem um nem sempre é a melhor para o mundo real. Duas tentativas de resolução:

1. Aumentar a ordem do processo Markov.
 - **Exemplo:** modelo de ordem 2 adicionando $Rain_{t-2}$ como pai de $Rain_t \rightarrow$ pode dar previsões mais precisas.
2. Aumentar o conjunto de variáveis de estado.
 - **Exemplo:** adicionar $Temperatura_t$, $Umidade_t$ e $Pressão_t \rightarrow$ permite o uso de um modelo físico para as condições de chuva.

4 INFERÊNCIA EM MODELOS TEMPORAIS

Uma vez obtida a estrutura de um modelo temporal, as seguintes inferências podem ser realizadas:

- **Filtragem ou monitoramento:** computar o estado de crença atual, dada toda a evidência até ao momento, ou seja, computar $P(X_t | e_{1:t})$.
Exemplo: Qual é a probabilidade de chuva hoje, dadas todas as observações guarda-chuvas até hoje?
- **Previsão:** computar distribuição posterior sobre algum estado futuro, dada toda a evidência até ao momento, ou seja, computar $P(X_{t+k} | e_{1:t})$ para $k > 0$.
Exemplo: Qual é a probabilidade de que irá chover daqui a três dias, dadas todas as observações de guarda-chuvas até hoje?
- **Suavização:** computar a distribuição posterior sobre algum estado passado, dada toda a evidência até ao momento, ou seja, computar $P(X_k | e_{1:t})$ para $0 \leq k < t$.
Exemplo: Qual é a probabilidade de ter chovido ontem, dadas todas as observações de guarda-chuvas até hoje?
- **Explicação mais provável:** encontrar a seqüência de estados que mais provavelmente geraram a seqüência de observações, ou seja, computar $\text{argmax}_{x_{1:t}} P(x_{1:t} | e_{1:t})$.
Exemplo: se o guarda-chuva apareceu nos primeiros três dias, mas não no quarto, então a explicação mais provável é que choveu nos primeiros três dias e não choveu no quarto dia.

4.1 FILTRAGEM OU MONITORAMENTO

O objetivo é obter uma estimativa recursiva. Dado o resultado de filtragem até o instante t , pode-se computar o resultado para $t+1$ utilizando a evidência e_{t+1} . Assim, para alguma função f :

$$P(X_{t+1} | e_{1:t+1}) = f(e_{t+1}, P(X_t | e_{1:t}))$$

Este processo é normalmente chamado de *estimativa recursiva*. O estado atual da distribuição é projetado de t para $t+1$, depois é atualizado utilizando uma nova evidência e_{t+1} :

$$\begin{aligned} P(X_{t+1} | e_{1:t+1}) &= P(X_{t+1} | e_{1:t}, e_{t+1}) \text{ (dividindo pela evidência)} \\ &= \alpha P(e_{t+1} | X_{t+1}, e_{1:t}) P(X_{t+1} | e_{1:t}) \text{ (usando a Regra de Bayes)} \\ &= \alpha P(e_{t+1} | X_{t+1}) P(X_{t+1} | e_{1:t}) \text{ (evidência de Markov)} \end{aligned}$$

Na equação acima, α é a constante de normalização. O termo $P(X_{t+1} | e_{1:t})$ representa a predição do estado seguinte e o termo $P(e_{t+1} | X_{t+1})$, que pode ser obtido diretamente do modelo sensor. Condicionando a variável X_t :

$$P(X_{t+1} | e_{1:t+1}) = \alpha P(e_{t+1} | X_{t+1}) \sum_{x_t} P(X_{t+1} | x_t, e_{1:t}) P(x_t | e_{1:t})$$

$$= \alpha P(e_{t+1} | X_{t+1}) \sum_{x_t} P(X_{t+1} | x_t) P(x_t | e_{1:t})$$

Dentro da somatória, o primeiro termo é o modelo de transição e o segundo termo é o estado atual da distribuição. Pode-se notar a recursividade na equação, pois há uma relação direta entre $P(X_{t+1} | e_{1:t+1})$ e $P(x_t | e_{1:t})$.

O termo $P(x_t | e_{1:t})$ pode ser visto como uma mensagem $f_{1:t}$ que é propagada para a frente ao longo da seqüência, modificada por cada transição e atualizada a cada nova observação. Assim:

$$f_{1:t+1} = \alpha \text{ FORWARD } (f_{1:t}, e_{t+1}),$$

onde FORWARD implementa a atualização descrita na equação.

4.1.1 EXEMPLO

Utilizando o mesmo exemplo do guarda-chuva, vamos supor que o guarda de segurança possui uma crença inicial sobre o fato de ter chovido no dia 0 e que esta crença seja de $\langle 0.5, 0.5 \rangle$.

Aplicando o modelo de transição para o dia 1:

$$P(R_1) = \sum_{r_0} P(R_1 | r_0) P(r_0) = \langle 0.7, 0.3 \rangle \times 0.5 + \langle 0.3, 0.7 \rangle \times 0.5 = \langle 0.5, 0.5 \rangle$$

Neste dia, o guarda-chuva aparece ($U_1 = \text{true}$). Atualizando com esta evidência:


$$P(R_1 | u_1) = \alpha P(u_1 | R_1) P(R_1) = \alpha \langle 0.9, 0.2 \rangle \langle 0.5, 0.5 \rangle = \langle 0.818, 0.182 \rangle$$

Aplicando o modelo de transição para o dia 2:

$$P(R_2 | u_1) = \sum_{r_1} P(R_2 | r_1) P(r_1 | u_1) = \langle 0.7, 0.3 \rangle \times 0.818 + \langle 0.3, 0.7 \rangle \times 0.182 = \langle 0.627, 0.373 \rangle$$

No dia 2, o guarda-chuva aparece novamente ($U_2 = \text{true}$). Atualizando com esta evidência:

$$P(R_2 | u_1, u_2) = \alpha P(u_2 | R_2) P(R_2 | u_1) = \alpha \langle 0.9, 0.2 \rangle \langle 0.627, 0.373 \rangle = \langle 0.883, 0.117 \rangle$$



4.2 PREVISÃO

Semelhante a filtragem, mas sem a adição de uma nova evidência.

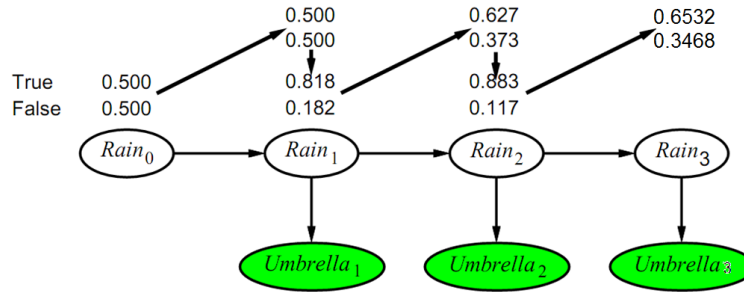
$$P(X_{t+k+1} | e_{1:t}) = \sum_{x_{t+k}} P(X_{t+k+1} | x_{t+k}) P(x_{t+k} | e_{1:t})$$

Esta computação envolve apenas o modelo de transição e não o modelo sensor.

4.2.1 EXEMPLO

Supondo o mesmo problema do guarda-chuva já apresentado. Vamos supor que o guarda de segurança queira saber se no dia 3 irá chover. Assim, aplicando o modelo de transição para o dia 3:

$$P(R_3 | u_2, u_1) = \sum_{r_2} P(R_3 | r_2) P(r_2 | u_2, u_1) = <0.7, 0.3> \times 0.883 + <0.3, 0.7> \times 0.117 = <0.6532, 0.3468>$$



4.3 SUAVIZAÇÃO

Suavização é o processo de computar a distribuição em algum instante de tempo passado k , dada a sequência completa de observações de 1 a t , ou seja, $P(X_k | e_{1:t})$, para $1 \leq k < t$. Isto é feito mais convenientemente em duas etapas: as evidências até o instante k e as evidências de $k+1$ até t :

$$\begin{aligned} P(X_k | e_{1:t}) &= P(X_k | e_{1:k}, e_{k+1:t}) \\ &= \alpha P(X_k | e_{1:k}) P(e_{k+1:t} | X_k, e_{1:k}) \text{ (Regra de Bayes)} = \\ &= \alpha P(X_k | e_{1:k}) P(e_{k+1:t} | X_k) \\ &= \alpha f_{1:k} b_{k+1:t} \end{aligned}$$

onde a mensagem *backward* $b_{k+1:t}$, análoga à mensagem *forward*, é computada por um processo recursivo que anda para trás a partir de t .

Abrindo o termo $b_{k+1:t} = P(e_{k+1:t} | X_k)$:

$$\begin{aligned} P(e_{k+1:t} | X_k) &= \sum_{x_{k+1}} P(e_{k+1:t} | X_k, x_{k+1}) P(x_{k+1} | X_k) \\ &= \sum_{x_{k+1}} P(e_{k+1:t}, e_{k+2:t} | x_{k+1}) P(x_{k+1} | X_k) \\ &= \sum_{x_{k+1}} P(e_{k+1} | x_{k+1}) P(e_{k+2:t} | x_{k+1}) P(x_{k+1} | X_k) \end{aligned}$$

Dentro da somatória, o primeiro termo é o modelo sensor e o terceiro termo é o modelo de transição. O segundo termo é que dá a recursividade na equação, pois há uma relação direta entre $P(e_{k+1:t} | X_k)$ e $P(e_{k+2:t} | x_{k+1})$. Utilizando a notação de mensagem, temos:

$$b_{k+1:t} = \text{BACKWARD}(b_{k+2:t}, e_{k+1:t})$$

Assim, na equação $\alpha f_{1:k} b_{k+1:t}$, os dois termos podem ser computados através da recursividade, um partindo de 1 até k , utilizando a equação da filtragem, e o outro, de t até $k+1$ utilizando a equação encontrada.

Notar que a fase de retrocesso é inicializada com $b_{t+1:t} = P(e_{t+1:t} | X_t) = 1$. (Devido ao fato de $e_{t+1:t}$ ser uma sequência vazia, a probabilidade de observação é 1).

4.3.1 EXEMPLO

Utilizando o mesmo exemplo anterior, vamos computar a probabilidade de chover no instante $t = 1$, dadas as observações de guarda-chuvas nos dias 1 e 2.

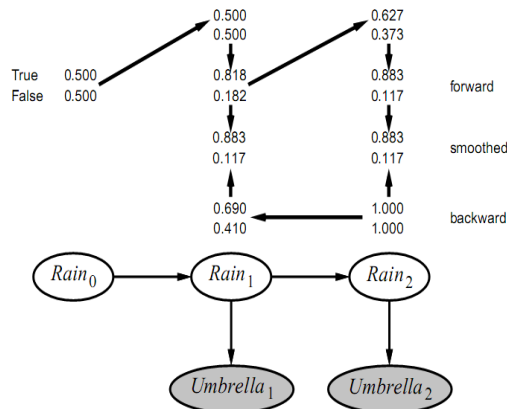
$$P(R_1 | u_1, u_2) = \alpha P(R_1 | u_1) P(u_2 | R_1)$$

O primeiro termo já foi calculado anteriormente, no processo de filtragem, onde foi obtido o valor $\langle 0.818, 0.182 \rangle$. O segundo termo pode ser computado aplicando o algoritmo de *backward*:

$$\begin{aligned} P(u_2 | R_1) &= \sum_{r_2} P(u_2 | r_2) P(r_2 | R_1) \\ &= (0.9 \times 1 \times \langle 0.7, 0.3 \rangle) + (0.2 \times 1 \times \langle 0.3, 0.7 \rangle) = \langle 0.69, 0.41 \rangle \end{aligned}$$


Assim:

$$P(R_1 | u_1, u_2) = \alpha \langle 0.818, 0.182 \rangle \times \langle 0.69, 0.41 \rangle = \langle 0.883, 0.117 \rangle$$



4.4 EXPLICAÇÃO MAIS PROVÁVEL

O algoritmo de explicação mais provável tem como objetivo traçar o a sequência mais provável. Para tal, ao invés de essa sequência se calculada como suavizações sobre cada espaço de tempo, o cálculo é feito assumindo cada sequência como um caminho sobre um grafo cujos nós são possíveis estados a cada timeslice.




O algoritmo consiste na premissa de que há um relacionamento recursivo entre os caminhos mais prováveis para cada estado x_{t+1} e os caminhos mais prováveis para cada estado x_t .

$$\begin{aligned} & \max_{x_1 \dots x_t} P(x_1, \dots, x_t, X_{t+1} | e_{1:t+1}) \\ &= c \alpha P(e_{t+1} | X_{t+1}) \max_{x_t} \left(P(X_{t+1} | x_t) \max_{x_1 \dots x_{t-1}} P(x_1, \dots, x_{t-1}, x_t | e_{1:t}) \right) \end{aligned}$$

No caso desta equação, a mensagem (analogamente aos algoritmos anteriores) é:

$$m_{1:t} = \max_{x_1 \dots x_{t-1}} P(x_1, \dots, x_{t-1}, X_t | e_{1:t})$$

O algoritmo necessita armazenar ponteiros que identificam a seqüência escolhida, por isso a complexidade espacial é igual a t , a complexidade temporal é igual ao tamanho da seqüência, t . Como, dependendo do problema, a solução pode ter um tamanho muito grande para a memória disponível à infra-estrutura, pode ser definida uma heurística que delimita a profundidade da busca.



A equação do algoritmo de Viterbi é:

$m_{1:t+1} = P(e_{t+1} | X_{t+1}) \max_{x_t} (P(X_{t+1} | x_t) m_{1:t})$, implementação é mostrada abaixo, nela fica explícita a recursão caracterizada pela passagem das mensagens.

$$\begin{aligned} m_t[x] &= \max_{x_{1:t-1}} P(x_{1:t-1}, x) \\ &= \max_{x_{1:t-1}} P(x_{1:t-1}) P(x | x_{t-1}) \\ &= \max_{x_{t-1}} P(x_t | x_{t-1}) \max_{x_{1:t-2}} P(x_{1:t-1}) \\ &= \max_{x_{t-1}} P(x_t | x_{t-1}) m_{t-1}[x] \end{aligned}$$

$$m_1[x] = P(x_1)$$

5 MODELO DE MARKOV OCULTO

O Modelo de Markov Oculto (HMM – Hidden Markov Model) é um modelo probabilístico temporal no qual o estado do processo é descrito por uma única variável. Variáveis de estado podem ser adicionadas a um HMM se forem combinadas formando uma “megavariável” cujos valores são todas as possíveis tuplas de valores das variáveis de estado individuais.

O HMM possibilita que os algoritmos vistos acima sejam implementados de uma forma elegante em forma de matrizes e seu uso possibilita a aplicação dos algoritmos em reconhecimento de padrões, como em reconhecimento de fala ou de escrita. O uso nesses casos é justificado pois não são sabidos todos os estados do problema, apesar de saber-se que o problema segue uma cadeia de Markov.

5.1 DEFINIÇÃO:

Um HMM é a tripla $M = (\Sigma, Q, \Theta)$, na qual:

- Σ é um alfabeto de símbolos.
- Q é um conjunto finito de estados, capaz de emitir símbolos do alfabeto Σ .
- Θ é o conjunto de probabilidades, constituído de:
 - Probabilidades de transição de estado, denotadas por a_{kl} para cada $k, l \in Q$.
 - Probabilidades de emissão, denotadas por $e_k(b)$ para cada $k \in Q$ e $b \in \Sigma$.

Um caminho $\Pi = (\pi_1, \dots, \pi_L)$ no modelo M é uma seqüência de estados. O estado segue uma cadeia de Markov simples, então, a probabilidade de se mover a um dado estado depende apenas do estado anterior. Como no modelo de cadeia de Markov, é possível definir as probabilidades de transição de estado em termos de Π :

$$a_{kl} = P(\pi_i = l \mid \pi_{i-1} = k)$$

Entretanto, em um HMM não há uma correspondência um para um entre os estados e os símbolos. Logo, em um HMM, introduz-se um novo conjunto de parâmetros, $e_k(b)$, chamado emissão de probabilidades. Dada uma seqüência $X = (x_1, \dots, x_L) \in \Sigma^*$ define-se:

$$e_k(b) = P(x_i = b \mid \pi_i = k)$$

$e_k(b)$ é a probabilidade de que o símbolo b seja visto quando está em um estado k .

Logo, a probabilidade de que a sequência X foi gerada pelo modelo M dado o caminho Π é:

$$P(X, \Pi) = a_{\pi_1, \pi_2} \cdot \prod_{i=1}^L e_{\pi_i}(x_i) \cdot a_{\pi_i, \pi_{i+1}}$$

Na qual denota-se $\pi_0 = \text{início}$ e $\pi_{L+1} = \text{fim}$.

5.2 ALGORITMOS MATRICIAIS SIMPLIFICADOS

Modelo Transacional:

O modelo $P(X_t | X_{t-1})$ se torna uma matriz T , $S \times S$ na qual:

$$T_{ij} = P(X_t | X_{t-1} = i)$$

Ou seja, T_{ij} é a probabilidade da transação do estado i ao j . No caso do exemplo do guarda-chuva:

$$T = P(X_t | X_{t-1}) = \begin{pmatrix} 0.7 & 0.3 \\ 0.3 & 0.7 \end{pmatrix}$$

Modelo do Sensor:

Para cada passo de tempo t , é construída uma matriz O_t cujas entradas diagonais são dadas pelo valor $P(e_t | X_t = i)$ e cujas outras entradas são zero. No exemplo do guarda chuva no qual $U_1 = \text{true}$

$$O_1 = \begin{pmatrix} 0.9 & 0 \\ 0 & 0.2 \end{pmatrix}$$

Forward/Backward:

A partir das definições anteriores, chega-se nos cálculos das mensagens de forward e de backward utilizadas nos algoritmos de filtragem, predição e suavização:

$$f_{1:t+1} = \alpha O_{t+1} T^T f_{1:t}$$

$$b_{k+1:t} = T O_{k+1} b_{k+2:t}$$

Que tem complexidade temporal de $O(S^2t)$, dado que matrizes são multiplicadas a cada passo e requer armazenagem de $O(St)$, t vetores de tamanho S .

Online Smoothing:

A representação matricial permite que seja facilitado cálculo da suavização, dado um intervalo entre os time slices cuja diferença de intervalos apresente um lag do qual o cálculo de suavização seja independente. Dado um lag d , o estado atual sendo t e será suavizado o time slice $t-d$, sem se alongar muito nos cálculos:

$$b_{t-d+2:t+1} = \begin{pmatrix} T O_i \\ \vdots \\ T O_i \end{pmatrix}_{i=t-d+2} b_{t+2:t+1} = B_{t-d+2:t+1} \mathbf{1}$$

$$\mathbf{B}_{t-d+2:t+1} = \mathbf{O}_{t-d+1}^{-1} \mathbf{T}^{-1} \mathbf{B}_{t-d+1:t} \mathbf{T} \mathbf{O}_{t+1}$$

As equações acima provêem uma maneira recursiva para o cálculo da suavização independente do tamanho do lag.